

Escuela de Ingeniería Eléctrica

IE0435 - Inteligencia Artificial Aplicada a la Ingeniería
Eléctrica

PROYECTO:
**Clasificación de contaminaciones
en una línea de producción
simulada**

Por: **Luis Enrique Pereira Barrantes**
C05859

Profesora Orientadora: **Prof. Marvin Coto**

San José, Costa Rica

14 de mayo de 2026

1. Introducción

En este proyecto se desarrolla un sistema de clasificación de imágenes orientado a la detección de contaminaciones en una línea de producción simulada. El objetivo principal es identificar la presencia de granos de arroz sobre una superficie blanca, distinguiéndolos tanto de otros objetos como de la ausencia total de elementos, mediante técnicas de aprendizaje automático clásico.

Para ello, se construyó un conjunto de datos propio y se diseñó un proceso de preprocesamiento que permite transformar la información visual en una representación adecuada para modelos de clasificación supervisada.

Posteriormente, se entrenaron y compararon distintos modelos clásicos de aprendizaje automático con el objetivo de determinar cuál presenta el mejor desempeño en la tarea de clasificación.

2. Recolección de datos

El conjunto de datos inicial se compone de un total de 30 imágenes, distribuidas equitativamente en dos clases:

- 15 imágenes positivas: contienen granos de arroz.
- 15 imágenes negativas: no contienen arroz, aunque pueden incluir otros objetos como clips u elementos similares.

Las imágenes fueron capturadas utilizando un dispositivo móvil, procurando mantener condiciones relativamente constantes de iluminación y un fondo uniforme (hoja blanca), con el fin de reducir variaciones no deseadas.

Adicionalmente, se introdujo variabilidad en la posición, cantidad y distribución de los objetos en cada imagen. Esto permite obtener un conjunto de datos más representativo y favorece la capacidad de generalización de los modelos entrenados posteriormente.

Para la segunda etapa del proyecto, los datasets individuales producidos por los distintos integrantes del grupo fueron combinados en un único conjunto de datos grupal, siguiendo el mismo procedimiento de preprocesamiento y representación.


El dataset grupal final quedó compuesto por un total de 118 muestras balanceadas entre clases positivas y negativas.

3. Ejemplos de imágenes

En la Figura 1 se presentan ejemplos representativos de ambas clases utilizadas en el conjunto de datos.



(a) Imagen positiva (con arroz)



(b) Imagen negativa (sin arroz)

Figura 1: Ejemplos de imágenes del conjunto de datos

4. Preprocesamiento de imágenes

Con el fin de estandarizar los datos y facilitar su uso en modelos de aprendizaje automático, se aplicó un preprocesamiento uniforme a todas las imágenes.

En primer lugar, cada imagen fue convertida a escala de grises, eliminando la información de color y reduciendo la complejidad del problema. Posteriormente, las imágenes fueron redimensionadas a una resolución fija de 128×128 píxeles, asegurando que todas las muestras tuvieran el mismo tamaño.

Finalmente, se realizó una binarización mediante un umbral fijo. En este proceso, los píxeles correspondientes al fondo (blanco) se codificaron con el valor 1, mientras que los píxeles asociados a objetos (como granos de arroz u otros elementos) se codificaron con el valor 0.

Este procedimiento permite obtener una representación consistente de cada imagen, adecuada para su posterior transformación en vectores de características.

5. Ejemplo de preprocesamiento

La Figura 2 muestra un ejemplo del proceso de transformación aplicado a una imagen del conjunto de datos.




Figura 2: Ejemplo del proceso de preprocesamiento aplicado a una imagen

6. Conformación del conjunto de datos

A partir de las imágenes preprocesadas se construyó el conjunto de datos final en formato tabular.

Cada imagen binarizada de tamaño 128×128 se transformó en un vector fila de longitud 16384 mediante el aplanamiento de la matriz de píxeles. A este vector se le añadió una última columna correspondiente a la etiqueta de clase.

Las etiquetas se definieron de la siguiente manera:

- 1: presencia de contaminación (granos de arroz)
- 0: ausencia de contaminación

El conjunto de datos individual resultante se almacenó inicialmente en un archivo CSV con un total de 30 filas y 16385 columnas.

Posteriormente, los datasets individuales de los distintos integrantes del grupo fueron combinados en un único archivo denominado `dataset_grupo.csv`, utilizado para el entrenamiento y evaluación de los modelos de clasificación.

7. Entrenamiento de modelos

Para la etapa de clasificación se evaluaron distintos modelos clásicos de aprendizaje automático utilizando la librería `scikit-learn`.

Los modelos evaluados fueron:

- K-Nearest Neighbors (KNN)
- Support Vector Machine (SVM)
- Decision Tree
- Naive Bayes

El conjunto de datos grupal fue dividido utilizando una partición estratificada de entrenamiento y prueba con una proporción 80/20. De esta manera, se garantiza una distribución balanceada de clases tanto en el conjunto de entrenamiento como en el conjunto de prueba.

Adicionalmente, se realizaron múltiples evaluaciones utilizando distintos valores de `random_state`, con el objetivo de analizar la estabilidad y capacidad de generalización de cada modelo.

8. Métricas de evaluación

Para evaluar el desempeño de los modelos se utilizaron las siguientes métricas:

- Accuracy
- Precision
- Recall
- F1-Score

Estas métricas permiten analizar el comportamiento de los modelos desde distintas perspectivas, considerando tanto la capacidad de detección de contaminaciones como la cantidad de falsas clasificaciones producidas.

9. Resultados experimentales

La Tabla 1 muestra el accuracy promedio obtenido por cada modelo considerando múltiples particiones del conjunto de datos.

Tabla 1: Resultados promedio obtenidos por los modelos evaluados

Modelo	Accuracy promedio
KNN	0.5208
SVM	0.8458
Decision Tree	0.7083
Naive Bayes	0.8708

Los resultados obtenidos muestran que el modelo KNN presentó el peor desempeño, mostrando un sesgo importante hacia la clase positiva. El modelo Decision Tree obtuvo resultados intermedios, mientras que SVM mostró un comportamiento estable y un desempeño competitivo.

El mejor resultado promedio fue obtenido por el modelo Naive Bayes, alcanzando un accuracy promedio de 0.8708. Por esta razón, dicho modelo fue seleccionado como modelo final del proyecto.

10. Exportación del modelo

Una vez seleccionado el mejor modelo, este fue entrenado utilizando la totalidad del dataset grupal y posteriormente exportado utilizando la librería `joblib`.

El modelo final se almacenó en el archivo: `modelo_final.joblib`

Esto permite reutilizar el modelo posteriormente sin necesidad de repetir el proceso completo de entrenamiento.

11. Conclusiones

El proyecto logró desarrollar un sistema básico de clasificación de imágenes utilizando técnicas de aprendizaje automático clásico.

El proceso incluyó la construcción de un conjunto de datos propio, el pre-procesamiento de imágenes, la generación de un dataset tabular y el entrenamiento de distintos modelos de clasificación supervisada.

Los resultados obtenidos muestran que el uso de un dataset grupal permitió mejorar la capacidad de generalización de los modelos respecto al conjunto individual inicial.

Finalmente, el modelo Naive Bayes fue seleccionado como la mejor alternativa para este problema, obteniendo el mayor accuracy promedio durante las pruebas experimentales.

Referencias

- [1] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830, 2011.
- [2] OpenCV Documentation. *Open Source Computer Vision Library*. Disponible en: <https://opencv.org/>
- [3] Reddit Community. *Discusiones sobre clasificación de imágenes y prepro-
cessing en machine learning*. Disponible en: [https://www.reddit.com/r/
MachineLearning/](https://www.reddit.com/r/MachineLearning/)
- [4] Coto Jiménez, Marvin. *Introducción a los Modelos Clásicos de Inteligencia
Artificial Aplicada a la Ingeniería Eléctrica*. Universidad de Costa Rica,
IE0435, I-2026. :contentReference[oaicite:0]index=0
- [5] OpenAI. *ChatGPT*. Modelo de lenguaje utilizado como apoyo para depu-
ración de código, organización del proyecto y redacción técnica. Disponible
en: <https://chat.openai.com/>